
МГТУ имени Баумана Факультет «Информатика и Системы управления» Кафедра «Системы обработки информации и управления» Дисциплина «Теория машинного обучения»

Отчет по	э лабораторной работ	re № 2									
«Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных»											
Выполнил: Студент группы ИУ5-61Б Гапчук Л.Д.		Преподаватель: Гапанюк Ю.Е.									

Цель лабораторной работы: изучение способов предварительной обработки данных для дальнейшего формирования моделей.

Задание:

- 1. Выбрать набор данных (датасет), содержащий категориальные признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.)
- 2. Для выбранного датасета (датасетов) на основе материалов лекции решить следующие задачи:
 - обработку пропусков в данных;
 - о кодирование категориальных признаков;
 - о масштабирование данных.



```
In [6]: data.info()
          <class 'pandas.core.frame.DataFrame'>
RangeIndex: 1429 entries, 0 to 1428
Data columns (total 8 columns):
               Column
                             Non-Null Count Dtype
           0
                title
                             1429 non-null
                                                object
                score
                             1429 non-null
                                                int64
                             1429 non-null
               id
                                                object
                url
                             445 non-null
                                                object
           3
                comms num 1429 non-null
           4
                                                int64
                             1429 non-null
                created
                                                float64
                             1064 non-null
                timestamp 1429 non-null
                                               object
          dtypes: float64(1), int64(2), object(5)
memory usage: 89.4+ KB
          Обработка пропусков
In [7]: # Удаляем столбцы, которые не несут значимой информации data.drop(['id','score'], axis = 1, inplace = True)
  In [8]: data.info()
            <class 'pandas.core.frame.DataFrame'>
            RangeIndex: 1429 entries, 0 to 1428
            Data columns (total 6 columns):
                              Non-Null Count Dtype
            # Column
                title
                              1429 non-null
                                                 object
                 url
                              445 non-null
                 comms_num 1429 non-null created 1429 non-null
             2
                                                 int64
                                                 float64
             4 body
                              1064 non-null
                                                 object
                 timestamp 1429 non-null
                                                 object
            dtypes: float64(1), int64(1), object(4) memory usage: 67.1+ KB
  In [9]: # Заполняем отсутствующие значения
            data = data.fillna("Num")
            data.head()
 Out[9]:
                                                                                                      url comms num
                                                                                                                             created body
                                                                                                                                                   timestamp
            0 Health Canada approves AstraZeneca COVID-19 va... https://www.canadaforums.ca/2021/02/health-can...
                                                                                                                    0 1.614400e+09 Num 2021-02-27 06:33:45
                   COVID-19 in Canada: 'Vaccination passports' a ...
                                                               https://www.canadaforums.ca/2021/02/covid-19-i...
                                                                                                                     1 1.614316e+09 Num 2021-02-26 07:11:07
             2
                   Coronavirus variants could fuel Canada's third...
                                                              https://www.canadaforums.ca/2021/02/coronaviru...
                                                                                                                    0 1.613887e+09 Num 2021-02-21 07:50:08
             3 Canadian government to extend COVID-19 emergen... https://www.canadaforums.ca/2021/02/canadian-g...
                                                                                                                     0 1.613796e+09 Num 2021-02-20 06:35:13
             4 Canada: Pfizer is 'extremely committed' to mee... https://www.canadaforums.ca/2021/02/canada-pfi...
                                                                                                                    0 1.613468e+09 Num 2021-02-16 11:36:28
In [10]: data.isnull().sum()
           # проверим есть ли пропущенные значения
Out[10]: title
           url
                          0
           comms num
                          0
           created
                          0
           body
           timestamp
           dtype: int64
```

```
Импорт библиотек
    In [1]: import numpy as np
            import pandas as pd
            import seaborn as sns
            import matplotlib.pyplot as plt
            %matplotlib inline
             from sklearn.impute import SimpleImputer
            from sklearn.model_selection import train_test_split
    In [2]: data = pd.read_csv('train.csv')
    In [3]: data.head()
    Out[3]:
                Passengerld Survived Pclass
                                                                                   Sex Age SibSp Parch
                                                                                                                            Fare Cabin Embarked
                                                                           Name
                                                                                                                   Ticket
             0
                                 0 3
                                                             Braund, Mr. Owen Harris
                                                                                 male 22.0
                                                                                                                A/5 21171
                                                                                                                         7.2500
                                                                                                                                  NaN
                                                                                                                                              S
                         2
                                        1 Cumings, Mrs. John Bradley (Florence Briggs Th...
                                                                                 female 38.0
                                                                                                      0
                                                                                                                PC 17599
                                                                                                                         71.2833
                                                                                                                                  C85
                                                                                                                                              C
                                 1 3 Heikkinen, Miss. Laina female 26.0
                                                                                                0 0 STON/O2. 3101282
                                                                                                                                              S
                                               Futrelle, Mrs. Jacques Heath (Lily May Peel) female 35.0
                                                                                                                  113803 53.1000
                                                                                                                                 C123
                                                                                             0
                                                             Allen, Mr. William Henry male 35.0
                                                                                                                  373450 8.0500
                                                                                                                                  NaN
In [4]: data['Embarked'].value_counts()
Out[4]: S
              644
              168
         Name: Embarked, dtype: int64
In [5]: # Кодируем признаки Pclass и Embarked в отдельные столбцы
         data = pd.get_dummies(data, columns=['Pclass','Embarked'])
In [6]: # Пол кодируем в 1/0
         data['IsMale']=data.Sex.replace({'female':0,'male':1})
data.drop('Sex', axis = 1, inplace = True)
In [7]: data.head()
Out[7]:
```


	Passengerld	Survived	Name	Age	SibSp	Parch	Ticket	Fare	Cabin	Pclass_1	Pclass_2	Pclass_3	Embarked_C	Embarked_Q	Embarked_S
0	1	0	Braund, Mr. Owen Harris	22.0	1	0	A/5 21171	7.2500	NaN	0	0	1	0	0	1
1	2	1	Cumings, Mrs. John Bradley (Florence Briggs Th	38.0	1	0	PC 17599	71.2833	C85	1	0	0	1	0	0
2	3	1	Heikkinen, Miss. Laina	26.0	0	0	STON/O2. 3101282	7.9250	NaN	0	0	1	0	0	1
3	4	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	35.0	1	0	113803	53.1000	C123	1	0	0	0	0	1
4	5	0	Allen, Mr. William Henry	35.0	0	0	373450	8.0500	NaN	0	0	1	0	0	1
4															→

Масштабирование значений


```
In [8]: from sklearn.preprocessing import StandardScaler, MinMaxScaler, StandardScaler, Normalizer
```

```
In [9]: sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data[['Age']])
```

In [10]: plt.hist(data['Age'], 50) plt.show()




In [11]: plt.hist(sc1_data, 50) plt.show()



```
In [12]: # Удаляем столбцы, которые не несут значимой информации data.drop(['Cabin','Name','Ticket'], axis = 1, inplace = True)
```

In [13]: sc2 = StandardScaler()
sc2_data = sc2.fit_transform(data[['Age']])

In [14]: plt.hist(sc2_data, 50)
plt.show()



In [15]: data.head()

Out[15]:

	Passengerld	Survived	Age	SibSp	Parch	Fare	Pclass_1	Pclass_2	Pclass_3	Embarked_C	Embarked_Q	Embarked_S	IsMale
0	1	0	22.0	1	0	7.2500	0	0	1	0	0	1	1
1	2	1	38.0	1	0	71.2833	1	0	0	1	0	0	0
2	3	1	26.0	0	0	7.9250	0	0	1	0	0	1	0
3	4	1	35.0	1	0	53.1000	1	0	0	0	0	1	0
4	5	0	35.0	0	0	8.0500	0	0	1	0	0	1	1